

Segmentierung des Magen-Darm-Trakts anhand von MRT Bildern mithilfe von Deep Learning

Viktor Leonardo Krawutschke

Bachelorarbeit

Beginn der Arbeit:	01. April 2010
Abgabe der Arbeit:	25. September 2022
Gutachter:	Univ.-Prof. Dr. S. Conrad Univ.-Prof. Dr. M. Kollmann

Erklärung

Hiermit versichere ich, dass ich diese Bachelorarbeit selbstständig verfasst habe. Ich habe dazu keine anderen als die angegebenen Quellen und Hilfsmittel verwendet.

Düsseldorf, den 25. September 2022

Viktor Leonardo Krawutschke

Zusammenfassung

Diese Bachelorarbeit beschäftigt sich mit der semantischen Segmentierung von MRT Bildern im medizinischen Bereich. Im Jahr 2015 wurde bei 5 Millionen Menschen Krebs im Gastro-Intestinaltrakt festgestellt, wovon die Hälfte für eine Strahlentherapie in Frage kommen. Diese dauert in der Regel 1 bis 6 Wochen und findet täglich für 15 Minuten statt. Dabei soll den Krebszellen gezielt eine hohe Strahlendosis verabreicht werden, gleichzeitig ist es zu vermeiden nicht betroffene Organe dabei in Mitleidenschaft zu ziehen. Problematisch ist, dass die Position der Organe und somit auch der Tumore von Tag zu Tag unterschiedlich ist. Dank Magnetresonanztomographen (MRT) und Linearbeschleunigern können Onkologen jedoch die genaue Position der Organe feststellen. Dies ist jedoch ein Zeitintensiver Prozess und dauert je nach Patienten zwischen 15 und 60 Minuten. Deep Learning könnte dabei helfen, diesen Prozess erheblich zu beschleunigen, um so Patienten zu entlasten und Ärzten die Chance zu geben mehreren Menschen im selben Zeitraum ihre Hilfe anzubieten.

Das UW-Madison Carbone Cancer Center hat im Rahmen einer Challenge auf Kaggle.com anonymisierte Scans von über 150 Patienten zur Verfügung gestellt, in denen manuell der Dickdarm, Dünndarm und der Magen von Fachleuten segmentiert worden ist. Ziel ist es, ein Modell zu entwerfen welches gegeben den Trainingsdaten dazu in der Lage ist in Bildausschnitten von vorher ungesehenen Patienten die Lokalität der genannten Organe in Form von einer Maske zu bestimmen. Baseline dieser Arbeit bildet ein Convolutional Neural Network, einem UNet Modell, welches auf 2 dimensional Daten antrainiert wurde, da es sich bewiesen hat Segmentierungen im Medizinischen Bereich vorzunehmen. Es besteht aus einem Encoder und einem "Decoder"Part, wobei wir verschiedene vortrainierte Encoder ausprobieren werden.

Auf einer detaillierten Datenanalyse aufbauend werden dann weitere Methoden angewendet, um die Performance zu verbessern. Es werden Trainingsdaten bereinigt und mit verschiedenen Eingabegrößen experimentiert. Ein weiterer Ansatz ist das intelligente beschneiden der Ausschnitte mit dem Ziel, dass sich das Modell besser auf die Aussagekräftigen Bereiche konzentrieren kann, sowie die Verwendung von "2.5 dimensional" Daten, auf die ich später genauer eingehe. Ein weiteres feature ist das intelligente Zuschneiden des Inputs. Zuletzt erfolgt eine Auswertung der Ergebnisse und es werden weitere Ideen genannt, die es nicht in die Arbeit geschafft haben.

Inhaltsverzeichnis

1 Verwandte Arbeiten	1
1.1 Semantische Segmentierung im medizinischen Bereich	1
1.2 Deep Learning-Techniken für die Segmentierung medizinischer Bilder: Errungenschaften und Herausforderungen	2
1.3 Intelligentes Zuschneiden des Inputs	2
2 Grundlagen	2
2.1 Magen-Darmtrakt	2
2.2 U-Net	2
2.3 Encoder 1	3
2.4 Encoder 2	4
3 Methodik	4
3.1 Datenanalyse	4
3.2 Metadatenextraktion	4
3.3 Algorithmik	5
3.4 2.5 dimensionale Daten	5
3.5 Intelligentes Zuschneiden	5
3.6 Nachbearbeitung	5
3.7 Experimente	5
4 Evaluation	5
5 Fazit	5
5.1 Ausblick	5
Abbildungsverzeichnis	10
Tabellenverzeichnis	10

1 Verwandte Arbeiten

1.1 Semantische Segmentierung im medizinischen Bereich

1.1.1 Semantische Segmentierung

Die semantische Segmentierung erfolgt in drei Schritten:

Klassifizierung: Klassifizierung eines bestimmten Objekts im Bild. Lokalisieren: Auffinden des Objekts und Zeichnen eines Begrenzungsrahmens um das Objekt.

Segmentierung: Gruppierung der Pixel in einem lokalisierten Bild durch Erstellung einer Segmentierungsmaske.

Im Wesentlichen kann man die Aufgabe der semantischen Segmentierung als Klassifizierung einer bestimmten Bildklasse und deren Abgrenzung von den übrigen Bildklassen durch Überlagerung mit einer Segmentierungsmaske bezeichnen.

Allgemein kann man es sich auch als Klassifizierung von Bildern auf Pixelebene vorstellen.

1.1.2 Medizinischer Bereich

Die medizinische Bildgebung umfasst viele Kategorien, von 2- bzw. 3 dimensionalen MRT Scans des Herzens, Gehirns und des Magen-Darm Trakts, 2 dimensionalen Röntgen Bildern sowie Ausschnitte aus der Videoendoskopie.

Bereits in den 90er Jahren wurde sich mit Segmentierungsarchitekturen auseinandergesetzt und baselines geschaffen. Zu dieser Zeit lieferten Methoden im Bereich „Pattern recognition“ die besten Ergebnisse. Die Autoren legten viel Wert auf preprocessing der Daten und werteten die zu jener Zeit besten Modelle aus. Es handelte sich um einen Feature basierten Ansatz, es wurden Algorithmen wie **kNN**, **Maximum Likelihood** und **Characteristic vector** getestet.

Trotz aller Bemühungen wiesen die Modelle nur eine Accuracy von 3% bis 34% auf. (Clarke:Mri1995)

Jedoch waren die Autoren davon überzeugt, dass segmentierung eine wichtige Rolle im Bereich der Verarbeitung von MRT Daten darstellen wird und mit wachsender Akzeptanz auf klinischer Seite sowie dem technischen Fortschritt der Hochleistungsrechner es in Zukunft möglich sein wird, akkurate Segmentierungen von MRT Scans im Livebetrieb vorzunehmen.

1.2 Deep Learning-Techniken für die Segmentierung medizinischer Bilder: Errungenschaften und Herausforderungen

Dank der immensen Verbesserung der Rechenleistung der Hardwarekomponenten wurde das Thema Deep Learning immer interessanter und gehört heutzutage zur standard Herangehensweise. Architekturen wie das U-Net Modell (**U-Net**) haben sich hierbei besonders bewiesen und wurden mit den Jahren nach der Veröffentlichung in 2015 stetig erweitert, so dass es für viele verschiedene (medizinische) Bereiche Architekturen vorliegen, die auf die jeweiligen Problemstellungen angepasst wurden, jedoch trotzdem Anwendung auf ähnlichen Gebieten finden können (**Hesamian**)

1.3 Intelligentes Zuschneiden des Inputs

Dimitrios G. Zaridis et al. (**SmartCrop**) haben sich ebenfalls mit verschiedenen State of the Art U-Net Architekturen auseinandergesetzt und eine Baseline geschaffen. Trotz der beachtlichen Leistung, die die Modelle liefern, sind sie der Meinung dass noch Verbesserungspotential vorhanden ist.

Sie fanden heraus, dass das Vorhandensein eines Klassenungleichgewichts, wo der Anteil der Hintergrundpixel dem Anteil des zu segmentierenden Organs überwiegt zu Problemen führen kann. Mithilfe eines Deep Learning Modells haben die Autoren es geschafft, dieses Klassenungleichgewicht zu reduzieren, in dem das Neuronale Netzwerk die gesuchten Organe lokalisiert, das Originalbild zuschneidet und am Ende das Verhältnis von Vorder- und Hintergrundpixeln normalisiert. Dies führte bei allen gängigen Deep Learning Netzwerken zu erheblichen Verbesserung im Bezug des Dice-Scores. U-Net+ und ResU-Net++ wiesen mithilfe dieser Technologie Verbesserungen von bis zu 8% auf.

2 Grundlagen

2.1 Magen-Darmtrakt

Um die Daten zu verstehen und Erkenntnisse aus den Ergebnissen zu gewinnen, ist es wichtig ein Grundverständnis für den Bereich des Körpers zu haben, den unsere Daten beschreiben. Wir interessieren uns in unserem Fall für den Dick- bzw. Dünndarm sowie den Magen. Hierbei liegt die Herausforderung, dass je nach Ernährungsverhalten, Schlafposition, anderen Krankheiten und Verdauung die Position der Organe stark (bzw. stärker als andere) variieren kann. Mithilfe der Grafik kann man sich ein Bild vom groben Aufbau machen. Figure 1

2.2 U-Net

U-Net wurde im Jahr 2015 von Olaf Ronneberger et al. (**U-Net**) vorgestellt als Segmentierungsarchitektur für den biomedizinischen Bereich und bildet die Baseline dieser Arbeit. Neu in der Herangehensweise ist der Encoder-Decoder Part, die dem Netzwerk ermöglicht räumliche Merkmale anzutrainieren. Klassisch handelt es sich um ein **Convolutio-**




Abbildung 1: Magen-Darm Trakt

nal Neural Network, bestehend es aus 5 bis 6 „downsampling“Schichten (auch Encoder genannt) und der gleichen Menge an „upsampling“Schichten (auch Decoder genannt).

Eine „downsample“Operation besteht zum einen aus einer „Convolution Operation“sowie einer „Max Pooling“an deren Ende jeweils eine „ReLU“Aktivierungsfunktion zum Einsatz kommt. In diesem Schritt lernt das Modell Eigenschaften auf Pixelebene, wie zum Beispiel Formen, Ecken, Kanten. Hierbei halbieren sich die Eingabedimensionen und die Tiefe des Bildes wird erhöht. Veranschaulicht kann man sagen, dass das Modell das „Was“lernt, was im Bild zu sehen ist. (Con97) Zur Semantischen Segmentierung fehlt dann nur noch das „Wo“, hierbei wird das Zusammenspiel von En- und Decoder deutlich.

Im Decoder wird das Bild wieder auf seine ursprüngliche Größe mittels „Transpose Convolution operations“gebracht. Hier ersetzt die transponier Operation die Maxpooling Operation (vergleich Grafik). Dieser Part erlaubt dem Modell das lokalisieren der zuvor gelernten Eigenschaften. Output ist eine Maske, bestehend aus Nullen und Einsen, die der Eingabegröße gleicht und bestenfalls den Wert Eins an der Stelle des gesuchten Organs enthält.

2.3 Encoder 1

Eventuell

Index	ID	Class	Segmentation
1	case134_day0_slice_0085	large_bowel	NaN
2	case134_day0_slice_0085	small_bowel	41591 5 41599 7 41949 27 ...
3	case134_day0_slice_0085	stomach	NaN
4	case123_day0_slice_0001	large_bowel	35223 6 74352 7 32312 12 ...
5	case123_day0_slice_0001	small_bowel	63432 5 12354 7 41949 12 ...
6	case123_day0_slice_0001	stomach	NaN

Tabelle 1: Beispieldaten für zwe slices

2.4 Encoder 2

Eventuell

3 Methodik

3.1 Datenanalyse

Der Datensatz besteht aus 115 488 Zeilen und enthält drei features: ID, Klasse und einem Run-length codierten String, der die Maske enthält. Table 1. Jeder ID sind drei Zeilen gewidmet, jeweils für die drei Klassen. Zu jeder ID existiert ein Graustufen Bild, welche sich im train Ordner befinden:

```
input\uw-madison-gi-tract-image-segmentation\train\case101\
case101_day20\scans\slice_0001_266_266_1.50_1.50.png
```

Ein Beispiel der Ordnerhierarchie kann man hier sehen Figure 4

Jedes slice enthält vier Zahlen (z.B. 266_266_1.50_1.50.png), die ersten beiden stehen für die Auflösung des Bildes und die letzten beiden für den physischen Abstand der Pixel. Der Großteil der Aufnahmen stammt von Tag null oder tag eins Figure 7 und die durchschnittliche Anzahl an Bildern pro Fall beträgt X.

Beim betrachten der Verteilung der Segmentierungen fällt auf, dass das Vorkommen für jede Klasse stark variiert. Figure 5.

3.2 Metadatenextraktion

Anhand der ID eines jedes Slices war es möglich verschiedene Metadaten dem originalen Dataframe zu entziehen, zudem wurde die gesamtlänge gedrittelt, dadurch dass die Klassen einer ID zugewiesen worden sind. Table 2

Idx	ID	large_bowel	small_bowel	stomach	case	day	slice	path	width	height	pixel_x	pixel_y
1	case134_day0_slice_0085	NaN	41591 5 ...	NaN	134	0	85	input\	266	266	1.5	1.5
2	case134_day0_slice_0086	41591 27 ...	NaN	NaN	134	0	86	input\	266	266	1.5	1.5
3	case134_day0_slice_0086	NaN	NaN	NaN	134	0	87	input\	266	266	1.5	1.5

Tabelle 2: Metadaten für drei slices

3.3 Algorithmik

Dieses Projekt wurde gänzlich in Python mithilfe der TensorFlow API sowie dem **Segmentation Models** (Yakubovskiy:2019) Package aufgezogen, welches verschiedene Architekturen und an- oder nicht antrainierte Encoder zur Verfügung stellt. Trainiert wurde mit dem **Adam Optimizer**, und einer initialen Learning Rate von $5e-4$, die sich um den Faktor $e-1$ verringert, wenn sich der Validation-loss nach fünf Epochen unverändert schlecht bleibt. Die Loss function ist eine Mischung aus **Binary Crossentropy** und zu 50% Dice Loss. Diese Kombination eignet sich laut Jadon (Jadon_2020) besonders gut, um Segmentierungsarchitekturen anzulernen. Ansonsten wurde mit einer Batchsize von 16 und 32 trainiert. Die Daten wurden mithilfe von der **StratifiedGroupKFold** Methode von Sklearn in 5 Folds aufgeteilt und nach Case gruppiert. Somit wurde das Verhältnis der Klassendistribution in jedem Fold beibehalten.

3.4 2.5 dimensionale Daten

?

3.5 Intelligentes Zuschneiden

?

3.6 Nachbearbeitung

?

3.7 Experimente

Experimente.

4 Evaluation

5 Fazit

5.1 Ausblick

Ideen, die es nicht in die Arbeit geschafft haben oder nicht schafften konnten.

Con97 hat ein Buch geschrieben. Es gibt auch andere Arbeiten (**PeHe97**) die referenziert sind. In Abbildung ?? ist ein Sachverhalt dargestellt.

1 Autor: **Con97** (Con97)

2 Autoren: **IWNLP** (IWNLP)

3 Autoren: **liebeck-esau-conrad:2016:ArgMining2016** (liebeck-esau-conrad:2016:ArgMining2016)

Online resource: **ILSVRC2016**

quotes:

Ein Beispiel für deutsche Anführungszeichen „quote“.




Abbildung 2: Beispiel MRT des Magen-Darm Traks. Zu sehen ist der Magen (rot) und der Tumor (pink) sowie die verabreichte Strahlendosis. Die Strahlenintensivität werden durch den Regenbogen der Umrisse dargestellt, wobei höhere Dosen rot und niedrigere Dosen grün dargestellt werden.

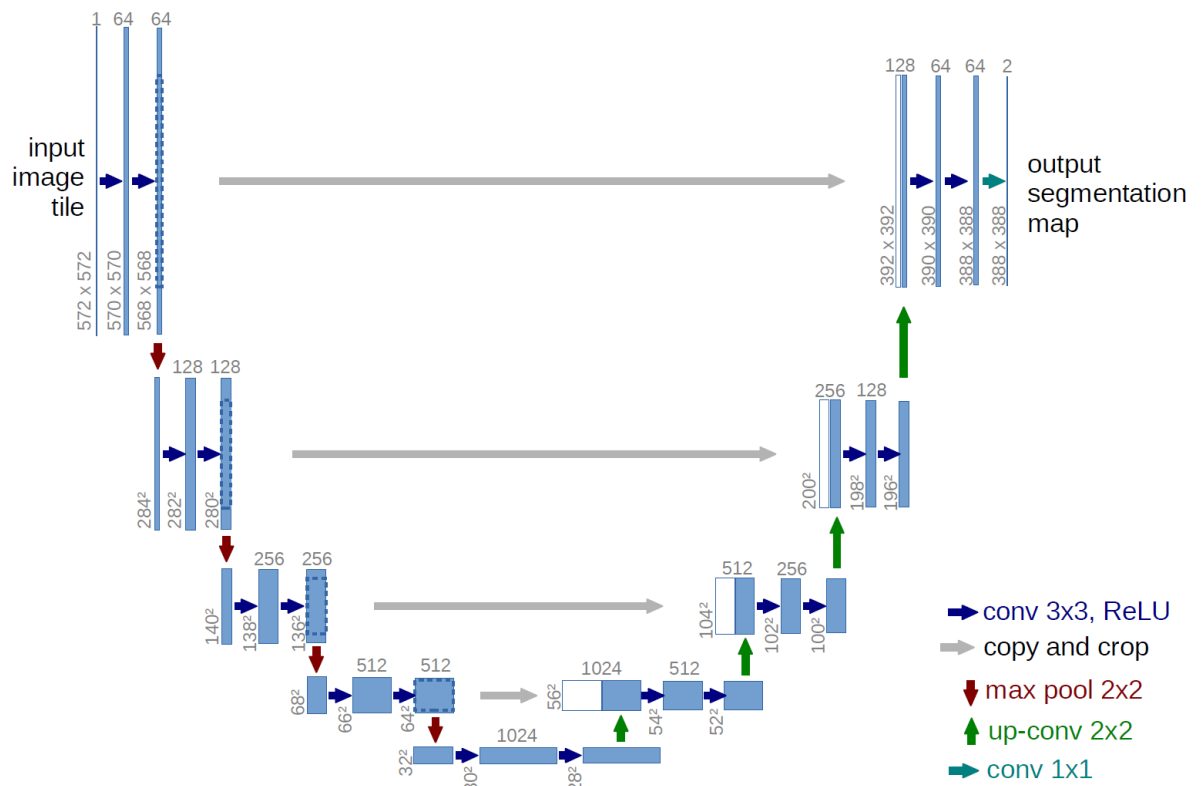


Abbildung 3: U-Net Architektur

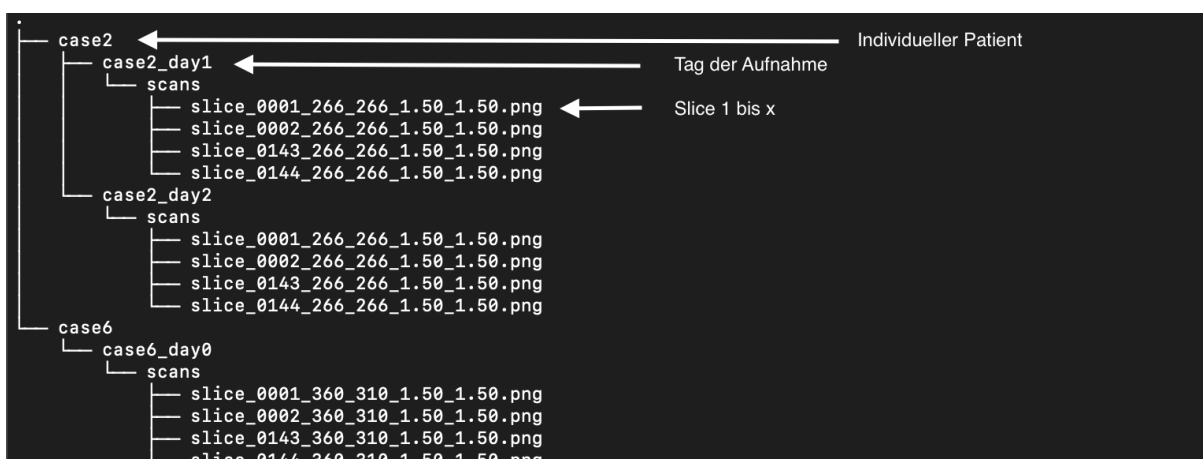


Abbildung 4: Trainingsdaten Hierarchie

Segmentation Distribution




Abbildung 5: Verteilung der Klassen im Testset

How many Slices do specific Cases have?

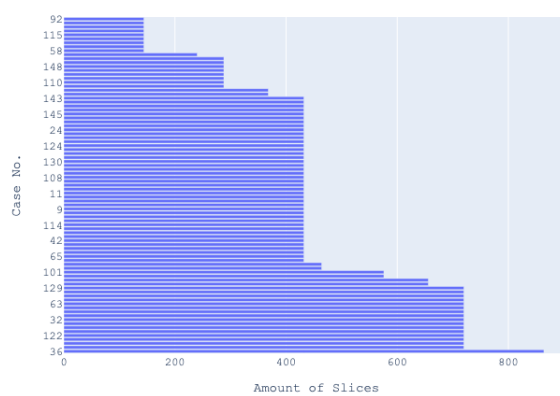


Abbildung 6: Anzahl Bilder pro Fall

How many slices do specific days have?




Abbildung 7: Anzahl Bilder pro Tag

Abbildungsverzeichnis

1	Magen-Darm Trakt	3
2	Beispiel MRT des Magen-Darm Traks. Zu sehen ist der Magen (rot) und der Tumor (pink) sowie die verabreichte Strahlendosis. Die Strahlenintensivität werden durch den Regenbogen der Umrisse dargestellt, wobei höhere Dosen rot und niedrigere Dosen grün dargestellt werden.	7
3	U-Net Architektur	8
4	Trainingsdaten Hierarchie	8
5	Verteilung der Klassen im Testset	9
6	Anzahl Bilder pro Fall	9
7	Anzahl Bilder pro Tag	9

Tabellenverzeichnis

1	Beispieldaten für zwe slices	4
2	Metadaten für drei slices	5